

项目简要说明（面试资料）


这份文档简单展示了我在病理图像上的完整项目实践，核心任务为**乳腺癌 ER 表达细胞检测**，涵盖从数据标注、模型训练到 **TensorRT** 推理的完整流程，在研究生实习阶段还有一个相关的实习经历**乳腺癌 HER-2 表达细胞检测**。此外，还进行了有关病理图像分割的任务**大尺寸图像的病灶分割实验**，用于对比不同滑窗融合策略以及分割模型在稀疏目标与边界处理中的表现。

一、乳腺癌 ER 表达细胞检测

1. 整体流程

- 标注与数据预处理：
 - 基于 QuPath + StarDist 构建辅助标注流程：通过 QuPath 脚本随机选取多个有组织的ROI区域，然后通过 StarDist 细胞分割模型自动生成细胞轮廓分割结果，并手动修正漏检目标与细胞类别（阳性/阴性）；
 - 获取 ROI 区域的标注后，需要将 StarDist 输出的分割轮廓转换为目标检测任务的矩形框形式标签（bounding box）；
 - 从Whole Slide Image 中提取 ROI 图像区域及对应的目标检测标签，构建训练数据集；

手动标注图像如下：



- 模型训练与导出：
 - 基于 YOLOv8 训练细胞检测模型，并构建“预测 + 修正”的半自动标注流程，迭代扩充训练集，以持续提升 ER 阳性肿瘤细胞等小目标的检测性能；
 - 在模型导出阶段，我将 YOLOv8 模型转换为支持动态输入维度（包括 batch size 和图像尺寸）的 ONNX 格式，并设置了 min/opt/max 的动态 profile。随后基于该模型构建了 FP16 精度的 TensorRT 引擎，以支持在推理阶段按需调整 batch size；
- TensorRT推理以及加速：
 - 采用滑动窗口 + 重叠裁剪方式对大图分块，自动跳过空白区域，避免冗余计算；
 - 使用生产-消费模型解耦图像裁切与推理任务，其中推理线程采用多 CUDA Stream + 多 batch 推理，提高推理速度；
 - 基于 CUDA 实现图像预处理、图像NMS后处理以及全图后处理NMS；
- 结果输出与可视化：
 - 推理输出经过全图级 NMS 聚合，最终结果以 GeoJSON 格式导出；

- 支持大尺寸图像推理与阳性率统计，便于后续分析；

过程中遇到几个关键细节问题：

- **坐标对不上的问题：** 原始图像是 .mrxs 格式，用 OpenSlide 无法准确获取到 QuPath 中的 ROI 区域的起始坐标，存在图层坐标偏移，应该和 3DHISTECH 的图像金字塔机制有关，OpenSlide 无法很好支持。最后，我直接使用 QuPath 导出的大尺寸 PNG 图像作为推理输入，暂时解决了坐标错位的问题。
- **图像边缘目标漏检：** 在滑动裁剪 patch 时，如果图像边缘剩下的部分不足一个完整 patch，默认会被丢弃，导致实际推理的时候，边缘区域经常漏掉边缘区域。通过对 Patch 的区域进行判断并进行边缘 padding 补齐操作，把不足 patch 的区域补成完整输入再推理，解决了边缘检测不完整的问题。
- **重叠区域重复检测：** 滑窗重叠推理会导致重叠区域的目标重复被检测，尤其是密集细胞区域，拼接结果容易重复计数。通过将整张图划成不重叠 grid，然后判断每个目标检测框是不是落在 grid 边缘以及分界线上，如果是，就统一归到上一块 grid，然后进行 NMS，以此完成对重叠区域目标的去重。

实际该阶段有两种做法：


- 只对重叠区域做 NMS，快速去重；如果滑窗推理中采用 640×640 patch 和 610 步长，存在 30 像素重叠。为避免重复统计目标，grid 边界应避免重叠区域，例如设置在 640-1220 区间，确保每个目标仅归属一个 grid；
- 对每个 grid 内所有目标重新聚合一次。那么这种方法需要注意的是左边界，需要小于当前重叠区域的左边界，大于上一个重叠区域的有边界，保证 grid 区域仅包括重叠区域；
- **生产线程裁剪的速度与推理线程的速度：** 只要生产速度 ≥ 推理速度，队列就不会空，推理线程就能持续取数据，不会阻塞等待。实际测试下来，生产线程裁剪速度通常能满足推理线程的需求。如果出现推理线程等待生产数据的情况，说明生产速度低于推理速度，需要调整生产速度或增加推理线程数量。

2. 推理结果：

下图是实际大尺寸病理图像（38463 × 25295）使用 TensorRT 进行推理的结果。左侧为原始染色图像，右侧为检测结果可视化图，其中红色表示 ER 表达阳性的肿瘤细胞，绿色为阴性细胞。

本次推理共处理 1550 张有效 patch（跳过 1138 张空白区域），检测细胞目标总数约 185 万，经全图级 NMS 去重后结果数保持一致。推理平均耗时约为 41 ms / patch，整体推理耗时约 60 秒，显存占用稳定在 1.45 GB。整体结果表明，该流程在本地设备上能够稳定处理超高分辨率图像。

为进一步评估模型在微观层面的识别能力，下方展示了若干局部区域的原图与检测结果对比图。从可视化结果来看，模型在细胞密集、染色清晰的区域表现稳定，基本能够还原细胞分布与分类信息。



推理日志:

图像尺寸: 38463 × 25295 px

Patch 总数: 2688

有效推理 Patch 数: 1550 (跳过空白区域 1138)

总检测目标数: 1,857,136

NMS 去重后目标数: 1,856,679

阳性细胞数: 680,716 (36.66%)

阴性细胞数: 1,175,963 (63.33%)

单 patch 平均推理耗时: **41.5 ms**

总推理时间: **60.6 秒**

GPU 显存使用: 1.45 GB / 16 GB

3. 乳腺癌 HER-2 表达细胞检测---研究生阶段实习（2023.9-2023.12）

该任务的核心目标是通过“癌区分割 + 细胞检测”的联合流程，辅助完成 HER-2 阳性率的自动统计与等级判定。我主要负责细胞检测模块，基于病理从业人员提供的标注数据，构建 HER-2 阳性与阴性细胞的检测模型，并参与部分癌区分割任务的实现。【免疫组化里面的所有指标计算都应该在肿瘤细胞的基础上去做，所以整体方案就是**癌区域分割+细胞检测分类**】

工作内容：

该项目的目标是通过区域分割 + 细胞检测的方式，完成对 HER-2 蛋白表达状态的自动分析与分类评估。整体流程如下：


- 癌区分割：使用区域分割模型提取癌区与非癌区，为后续细胞级分析提供空间限定；
- 细胞检测与分类：对每个区域内的细胞进行检测，并判断其是否表达 HER-2 蛋白（阳性 / 弱阳性 / 阴性），生成对应检测框与分类标签；
- 结构化统计输出：统计各个癌区中的阳性细胞数量、比例、表达等级，并提供图像级评估指标；


我主要负责细胞检测模块的实现，具体包括：

- 基于病理专家提供的标注，构建 HER-2 阳性/阴性细胞检测数据集，并完成清洗与格式转换；
- 使用 YOLO 系列模型训练细胞检测器，支持高密度细胞识别与分类；
- 输出结构化检测结果，用于后续癌区筛选与 HER-2 阳性率统计；

下图展示的是多个 ROI（感兴趣区域）的检测可视化效果：以点的形式可视化细胞类别 HER-2 阳性（红/紫色圈）、弱阳性细胞（黄色圈）与阴性细胞（绿色圈），覆盖区域边界良好，能较好还原实际形态。此外，还展示了结合癌区域分割+细胞检测的检测结果，底部结果表格展示的是切片局部的统计数据，包括：切片编号、癌区细胞总数、阳性细胞数。

注：该检测模型的推理结果在误差允许范围内，被认为**初步**可以接受。





二、大尺寸医学图像的分割

该任务是对大尺寸医学图像中的病灶进行语义分割对比实验，主要围绕眼底图像中的多种病灶（如出血、微血管瘤、硬性渗出、软性渗出、视盘等）以及病理图像的恶性病灶区域。

1.实验内容

数据预处理与样本生成

实验数据来源于两个高分辨率医学图像数据集：眼底图像（IDRID）和结肠镜病理检查图像（DigestPath 2019）。由于原始图像尺寸较大（通常为几千 × 几千像素），难以直接用于模型训练，因此在预处理阶段通过滑动窗口裁剪生成固定大小的 Patch，用于模型训练。

这两个数据集在病灶特征上存在显著差异，因此采用了不同的处理策略：

- 眼底图像（IDRID）：包含多种病灶类型（如出血、微血管瘤、硬性渗出等），为多类语义分割任务；
- 结肠镜病理图像（DigestPath 2019）：对来自不同医疗中心的病理组织图像进行二分类语义分割；

眼底图像

在视网膜病变图像分割任务中，图像病灶的类型与复杂度往往随病变程度而显著增加。不同病灶在颜色、形态和空间分布上的差异，对模型的判别能力要求也不同。例如，渗出物与出血在形态结构上显著不同，但渗出物与视盘的亮度特征相似，出血区域的色调又常与正常血管高度接近。这些视觉上的相似性，可能会导致模型在细粒度识别阶段产生混淆，尤其在边界模糊或区域过小的情况下更为明显。

基于这一认识，在实验初期，我尝试引入图像预处理，以提升病灶区域与背景之间的显著性。其中包含三个主要步骤：


- CLAHE（自适应直方图均衡化）：提升局部对比度，使低对比度病灶区域更清晰；
- 高斯滤波：抑制噪声，平滑纹理，降低图像冗余细节；
- 差值增强：将原图与模糊图进行加权相减，强化边缘轮廓，突出前景目标。

$$I_{(G)} = G_{\varsigma} * I_{(G)}$$

$$G_{\varsigma} = \frac{1}{\sqrt{2\pi\varsigma}} e^{-\frac{x^2+y^2}{2\varsigma^2}}$$

$$I_d = \omega \cdot I + \theta \cdot I_{(G)} + \varsigma$$

其中， $\omega = 4$ ， $\theta = -4$ ， $\varsigma = 128$ ；



预处理方法来源于研究生阶段小论文 [特征自适应过滤的视网膜病变分级算法](#)

眼底图像的 Patch 提取方式：

针对部分 patch 前景过少甚至缺失的问题，我通过对像素标签的类别进行采样，确保每类目标均能被充分覆盖，且前景目标位于 patch 中心，主要步骤：


- 按类别标签信息提取 patch，确保每个采样区域包含对应类别的前景像素，避免纯背景 patch 干扰；
- 对于在图像中出现频次较低的类别，适当增加其采样数量，以缓解类别不均衡带来的偏差；
- 为防止 patch 采样过于集中在同一区域，引入随机偏移扰动 patch 中心位置，提升 Patch 的空间多样性；

我分别对普通滑动裁剪（基础策略）与 类别采样方式进行了对比实验。在使用相同网络结构与训练设置的条件下，基于像素标签的类别进行采样的方法能够提升模型在小病灶区域的整体分割精度（提升 1.03% 的 Dice，1.19% mIoU）。

结肠镜病理图像

经过阅读相关文献了解到，病理图像的染色效果在不同医疗中心之间差异较大，主要受到染色浓度、切片厚度、扫描设备以及制备流程等因素影响。这些因素会导致同一种组织在不同图像中的颜色表现不一致。如果不进行颜色归一化处理，模型可能会学习到与结构无关的颜色特征，进而影响对实际组织结构的识别。因此，颜色归一化在病理图像预处理阶段是一个关键步骤。

常见的颜色归一化方法包括 Reinhard、Macenko 和 Vahadane，我使用的是 Vahadane 方法，它基于稀疏非负矩阵分解（SNMF），将图像分解为染色基（stain matrix）和浓度矩阵（concentration matrix），从而实现不同图像之间颜色风格的一致化，同时尽可能保留原始的结构信息。下图展示了使用 Vahadane 方法进行颜色归一化前后的图像对比效果：（在进行颜色归一化前，同样需要预处理，保证标准图像的准确性，后续需要补充）



注：使用该方法的原因来源该技术博客 [《染色归一化》病理图像（HE或者WSI）图像标准化方法小介绍](#)

病理图像的 Patch 提取方式：

在构建病理图像的分割训练数据时，我对原始高分辨率病理图像进行了滑动窗口裁剪，生成固定大小的 Patch。采样过程中需兼顾组织结构的多样性以及正负样本的数量平衡。具体流程如下：

- 阳性样本（含病灶图像）
 - 跳过掩膜全为 0 的区域，只保留含前景的 Patch，优先选择前景像素占比较高的 Patch，避免训练中大部分区域为背景；
- 负样本（无病灶图像）
 - 尽量在组织结构清晰、分布均匀的区域中采样，同时也需要避免 Patch 过于集中；
- 样本比例控制
 - 最终 Patch 数据中，阳性与负样本数量比例约为 1 : 1，在保证前景信息充分的同时维持训练集的平衡；

模型训练与推理

实验基于经典的医学图像语义分割网络 U-Net 及其改进结构展开，由于实验方案持续调整，部分中间阶段的模型指标未被完整记录，但整体训练流程已在本节中充分呈现。

实验结果

表中仅列出部分代表性结果以供参考。

模型名称	Dice（眼底）	mIoU（眼底）	Dice（病理）	mIoU（病理）
UNet	0.8589	0.8815	0.9086	0.8650
UNet++	0.8546	0.8111	0.9041	0.8579
DeepLabV3+	0.8500	0.8099	0.9112	0.8673

表中列出了三种主流模型在眼底图像与病理图像任务中的代表性评估指标（Dice 与 mIoU）。从结果可见，各模型在不同任务中的性能表现存在差异：

- UNet：在两个任务中均取得较高的 Dice 系数，整体表现稳定，具有良好的泛化能力，适合作为基线模型；
- UNet++：尽管其嵌套结构有助于边界细节恢复，但在眼底图像任务中 mIoU 略低，可能对小病灶或复杂背景的适应性略逊；

- DeepLabV3+：在病理图像任务中取得最高 Dice (0.9112)，表明其基于空洞卷积和 ASPP 的结构更利于捕获上下文信息；但在眼底图像任务中性能相对较弱，可能与其对细粒度边界建模能力不足有关；

大尺寸图像滑窗推理与后处理

因为整个流程都是基于 patch 的，所以我主要对比了两种滑窗方式：

- 滑窗无重叠：推理速度快，但边缘容易断，尤其是病灶刚好落在 patch 边缘时，可能会漏掉。
- 滑窗有重叠 + 融合：为了解决边缘断裂问题，引入重叠区域，然后用不同策略融合重叠区域的预测结果。

融合方式我试了三种：

- 最大值法：简单粗暴，哪个 patch 预测值大就用哪个。但有时候会导致边界不连续，看起来“跳”。
- 均值法：把多个 patch 的结果平均一下，平滑自然，但容易把病灶响应“拉低”。
- 高斯加权法：为每个 patch 生成以中心为权重峰值的高斯分布 mask，在融合阶段按像素加权叠加多个 patch 的预测结果。该方法能够有效平滑边缘接缝、强化中心区域响应，但在某些情况下可能引入局部假阳性，特别是在背景区域中心与前景区域中心权重相近时；

2. 实验结果示例（小目标分割）

眼底图像

对 IDRiD 数据集中的眼底图像进行病灶分割实验结果如下，模型输出类别与颜色约定如下：

病灶类别	英文名称	可视化颜色
微血管瘤	Microaneurysms	红色
出血	Haemorrhages	绿色
硬性渗出物	Hard Exudates	蓝色
软性渗出物	Soft Exudates	黄色
视盘	Optic Disc	品红色

当前分割效果较好：

- 视盘（Optic Disc）识别较为稳定，预测区域完整，边界清晰，与真实结构高度一致，在所有样本中表现较好，说明模型对结构性强、形态稳定的目标较敏感。
- 硬性渗出物分割效果可接受，能较稳定检测出块状、高反光区域，有一定程度的区域完整性，误检率不高。

当前分割存在的问题：


- 微血管瘤检测存在较多假阳性，多处预测为红色点状区域，但在非病灶区域也有大量预测，小目标的分割能力有限。
- 软性渗出物容易漏检，初步分析原因是因为训练集中该类样本占比较少，或模型特征不敏感。
- 出血区域边界模糊、膨胀现象明显，与其他类别（如软渗）存在边界混淆，导致轮廓不规则或分类错误。

注：对小目标的分割能力不足，主要原因在于网络在下采样过程中会丢失大量细粒度信息，同时受限于感受野和特征整合方式，模型对局部区域的上下文建模能力有限。


可能优化方向：

- 引入多尺度结构（如 FPN 或金字塔池化模块）以增强模型对微血管瘤等小病灶的识别；
- 采用类别引导采样或调整类别损失权重，以提高模型对软性渗出物等低频类别的敏感性；
- 引入边界感知损失函数与置信度平滑策略，提升模型对边界模糊区域的判别能力，降低假阳性发生率；

备注：当前模型更擅长识别结构性、区域明确的目标，如视盘、硬性渗出物。对于点状或边界模糊的类别（微血管瘤、软渗）较弱。



注：原图中红色为硬性渗出物、蓝色为微动脉瘤，藏青色为出血；后面的标签以及预测结果中蓝色为硬性渗出物，红色为微动脉瘤（未显示出来），黄色为出血。



病理图像

在 DigestPath 2019 病理图像分割实验中，模型在以下方面表现较好：

- 模型对病灶主体区域（如腺体团块）的分割效果较好，预测结果轮廓清晰、结构完整，尤其在染色均匀、背景干净的图像中，分割区域与人工标注较为一致；
- 图像中心区域的响应相对稳定，推测与 patch 中心特征信息更完整有关。滑动窗口推理中使用重叠裁剪和加权融合后，图像整体结构连贯性明显提升；

- 引入滑窗重叠和融合策略后，**拼接边缘断裂的问题有一定程度缓解**，尤其在结构连续区域更为明显；

当前观察到的问题：

- 模型对细小、孤立、条带状病灶识别能力不足，推理输出值偏低，阈值后易被过滤，出现假阴性。
- 错误主要分布在 patch 边缘区域，表现为轮廓不连续、断裂、偏移或形变，即使采用高斯加权融合，边缘响应仍不稳定；
- 部分空白或染色不均区域被误判为前景，表明模型可能受到背景纹理干扰，或训练中负样本标注覆盖不全；

后续优化方向：

- 可通过单独增强小病灶区域的采样或训练样本，增加难例覆盖，提升模型对小目标的敏感性（通过面积筛选，小块孤立区域）；
- 可清洗负样本标签并加强背景区域训练，同时在推理后加入小区域过滤，抑制离散误检；

备注：实验验证了基础结构与滑窗策略的可行性，但分割质量仍受限于小目标建模、边缘一致性与结构复杂度的影响。

